Quantum Generative Adversarial Networks for Addressing Security Data Imbalance and Causal Attribution of QBER

Alfonso Zappia, Nicola Frugieri
Studenti (Matr. NF22500012, 0522501966)
{a.zappia, n.frugieri}@studenti.unisa.it

Franco Cirillo, Maria Caterina D'Aloia
Tutor di Ricerca
{fracirillo, mdaloia}@unisa.it

Christian Esposito
Docente del Corso
Dipartimento di Informatica
c.esposito@unisa.it

***Abstract*—La generazione sintetica puo' ampliare la copertura dei dati di sicurezza, ma fedelta' statistica e utilita' nel compito finale non coincidono necessariamente. Questo studio valuta una Quantum Generative Adversarial Network (QGAN) ibrida, con generatore parametrico a cinque qubit e discriminatore classico, in due casi di studio: generazione condizionata di osservabili BB84 da simulazioni QKD e augmentation di attacchi minoritari su NSL-KDD. Nel dominio QKD si introduce inoltre, come componente complementare e indipendente dal generatore, una procedura di attribuzione controfattuale del QBER con target definiti a livello di bit e un attributore classico. L'architettura generativa puo' essere riutilizzata nei due domini, ma richiede calibrazioni e tempi di convergenza specifici. Su QKD, la generazione condizionata supera baseline semplici ma non l'interpolazione di osservazioni da celle vicine; il 99,1% della discrepanza stimata del generatore condizionato e' associato alla componente di media. Su IDS, la QGAN corretta nei momenti migliora la PR-AUC rispetto a SMOTE su KDDTest+ di 0,1237, senza evidenza di un vantaggio robusto rispetto a una gaussiana a momenti corrispondenti. L'attribuzione controfattuale e' verificata nel simulatore tramite composizione XOR e accoppiamento dei numeri casuali, senza rivendicare un miglioramento dell'attributore tramite la QGAN. Tre conclusioni intermedie sono state ritirate dopo controlli definiti prima delle relative misure, evidenziando il contributo metodologico del protocollo di valutazione.**

***Index Terms*—Quantum Machine Learning, QGAN, Quantum Key Distribution, Network Security, Counterfactual Attribution, Data Augmentation.**

I. Introduzione

La disponibilita' di esempi rappresentativi e' fondamentale nei sistemi di sicurezza, ma assume forme differenti a seconda del dominio. Nelle reti per la distribuzione quantistica di chiavi (QKD), il Quantum Bit Error Rate (QBER) segnala un degrado della comunicazione, ma non identifica da solo se esso dipenda da intercettazione, rumore del canale o imperfezioni dei rivelatori. Nei sistemi di rilevamento delle intrusioni (IDS), invece, attacchi poco frequenti possono essere scarsamente rappresentati nei dati di addestramento: un classificatore apprende da pochi esempi e puo' degradare quando incontra tipologie non osservate. La modellazione delle osservabili QKD e l'attribuzione dei relativi errori costituiscono quindi problemi distinti da quello dello sbilanciamento IDS.

I modelli generativi offrono un possibile supporto a entrambi gli scenari: possono sintetizzare osservazioni QKD per configurazioni escluse dall'addestramento oppure ampliare il training set IDS. Rimane tuttavia da verificare se la capacita' di apprendere una distribuzione si traduca in un beneficio rispetto a metodi classici semplici. A questo scopo adottiamo una QGAN ibrida e ne valutiamo la struttura condivisa in due casi di studio, mantenendo distinti i rispettivi compiti applicativi.

La ricerca e' articolata in tre obiettivi: **O1**, verificare la portabilita' dell'architettura generativa fra i due domini a dimensionalita' fissata; **RQ2**, valutare la generazione condizionata di osservazioni QKD per configurazioni escluse e l'utilita' dell'augmentation sul riconoscimento degli attacchi IDS; **O3**, definire e verificare target controfattuali per attribuire gli errori QKD a cause fisiche e costruire un riferimento classico per la loro predizione.

I contributi sono quindi: (i) una specifica QGAN ibrida comune ai due domini, con calibrazione separata; (ii) una procedura controfattuale verificata e una baseline classica di attribuzione del QBER; (iii) una valutazione della generazione QKD condizionata su celle escluse e dell'errore di media e di forma; (iv) un confronto dell'augmentation IDS con SMOTE, perturbazioni e distribuzioni gaussiane, incluso un controllo dei momenti. Il contributo controfattuale e' *complementare* alla QGAN: non e' stato eseguito l'esperimento in cui l'attributore viene addestrato sulle finestre sintetiche generate dal circuito. Tale distinzione determina anche i limiti delle conclusioni.

II. Stato dell'arte

A. Modelli generativi quantistici

Le Quantum Generative Adversarial Networks integrano circuiti quantistici parametrizzati in schemi di apprendimento avversario. Zoufal, Lucchi e Woerner [1] studiano l'apprendimento e il caricamento di distribuzioni tramite circuiti variationali. L'interesse applicativo consiste nel rappresentare distribuzioni multivariate con un generatore addestrabile; cio' non implica, di per se', un vantaggio rispetto a un modello generativo classico calibrato sul medesimo compito.

B. Reti QKD e attribuzione degli errori

BB84 [2] rende il QBER un indicatore centrale della qualita' del canale e di possibili intercettazioni. Xu *et al.* [3] impiegano metodi di apprendimento automatico per identificare imperfezioni e attacchi in sistemi QKD pratici (accuratezza

riportata del 98%); Isha *et al.* [4] analizzano pattern temporali del QBER per distinguere tipologie di attacco. Questi lavori sono pertinenti alla diagnosi, ma il problema qui considerato e' differente: costruire, in simulazione, quote relative di errore a causa singola e studiarne la predicibilita' su configurazioni fisiche escluse. La stessa rappresentazione delle osservabili e' inoltre impiegata per valutare separatamente la generazione condizionata.

C. Augmentation per IDS

Lo sbilanciamento dei dati e le diverse famiglie di attacchi sono problemi consolidati nella letteratura sugli IDS [5]. SMOTE [6] sintetizza esempi mediante interpolazione di istanze minoritarie. In presenza di attacchi non osservati nel training e' dunque necessario valutare non soltanto la fedelta' ai campioni disponibili, ma anche l'utilita' dei sintetici su un insieme di test esterno e con baseline non interpolative.

III. Architettura condivisa

La Figura 1 sintetizza le due applicazioni: dati IDS e osservazioni QKD alimentano, in addestramenti distinti, il medesimo schema generativo; nel ramo QKD un attributore classico separato riceve le osservabili e predice quote controfattuali. La condivisione riguarda i cinque qubit, l'ansatz e la struttura degli strati nascosti, non le feature, i pesi appresi o tutte le dimensioni di ingresso del discriminatore.

A. Generatore quantistico

Il generatore G_θ e' un circuito parametrizzato a cinque qubit, implementato con Qiskit 2.5.2 e Qiskit Aer o, nelle campagne con molte repliche, con un simulatore a vettore di stato denso vettorizzato per minibatch. Usa un ansatz `EfficientSU2` di quattro ripetizioni, entanglement lineare e 50 parametri addestrabili. Il rumore latente $z_i \sim \mathcal{U}(0, r)$ e' codificato mediante rotazioni $RY(z_i)$; ciascuna uscita $\hat{x}_i \in [0, 1]$ e' la probabilita' marginale dello stato $|1\rangle$ sul qubit corrispondente. Nel ramo QKD le tre condizioni fisiche c sono iniettate tramite rotazioni $RZ(\pi c)$ con *data re-uploading* in due punti del circuito. Il ramo IDS impiegato nelle misure e' non condizionato.

B. Discriminatore e ottimizzazione

Il discriminatore D_ϕ e' una rete MLP $5+d_c \to 32 \to 16 \to 1$, con LeakyReLU ($\alpha = 0{,}01$), uscita sigmoidale e Jacobiana analitica implementata in NumPy. Vale $d_c = 3$ nel ramo QKD e $d_c = 0$ nel ramo IDS; dunque la struttura comune non implica identica larghezza del primo strato. Il criterio avversario e'

$$\min_\theta \max_\phi V(D_\phi, G_\theta) = \mathbb{E}_{x\sim p_{\text{data}}}[\log D_\phi(x \mid c)] + \mathbb{E}_{z\sim p_z}[\log(1 - D_\phi(G_\theta(z \mid c) \mid c))]. \tag{1}$$

Il gradiente del circuito concatena la Jacobiana del discriminatore con la *parameter-shift rule* [7], [8]:

$$\frac{\partial G^i_\theta}{\partial \theta_j} = \frac{1}{2}\left[G^i_{\theta+\frac{\pi}{2}e_j} - G^i_{\theta-\frac{\pi}{2}e_j}\right]. \tag{2}$$

I parametri sono aggiornati con Adam. L'arresto precoce del generatore e' guidato dalla Maximum Mean Discrepancy (MMD) [9], stimata con una U-statistica non distorta e stratificata per condizioni ove applicabile. Il budget massimo e' di 5.400 passi per dominio.

C. Feature freezing e calibrazione

Il *feature freezing* fissa l'uscita a cinque variabili e mantiene ansatz, numero di qubit, strati nascosti e procedura di addestramento. Nel dominio QKD le componenti corrispondono a cinque osservabili fisiche; su IDS sono cinque componenti principali ottenute da NSL-KDD. Si tratta quindi di due addestramenti indipendenti sulla stessa struttura, non di trasferimento diretto dei pesi. Il raggio latente e' calibrato sulla dispersione media all'inizializzazione e assume $r = 0{,}82$ su QKD e $r = 0{,}93$ su IDS. Tale calibrazione scalare non garantisce l'allineamento della dispersione di ogni singola variabile: l'effetto viene ripreso nella discussione.

IV. Dati e protocolli sperimentali

A. Dominio QKD

Le osservazioni provengono da simulazioni BB84 in NetSquid [10], non da un apparato fisico. La griglia stazionaria comprende 120 celle definite dall'intensita' di intercettazione $I_e \in [0{,}00; 1{,}00]$, dalla lunghezza della fibra $L \in \{5, 10, 20, 40\}$ km e dalla depolarizzazione totale $D_{\text{tot}} \in [0{,}010; 0{,}060]$. Ogni cella e' simulata con cinque semi indipendenti: in totale 94.170 finestre di 200 bit setacciati, con blocchi di riferimento di 10^5 bit. Le celle interne sono 24, quelle di bordo 96. Ciascuna finestra e' rappresentata da

$$X = \big[\texttt{qber},\ \texttt{qber_rect},\ \texttt{qber_diag},\ \texttt{sift_rate},\ \texttt{loss_rate}\big] \in \mathbb{R}^5. \tag{3}$$

La `basis_asymmetry`, pari a $|\texttt{qber_rect} - \texttt{qber_diag}|$, e' ridondante, mentre `qber_stability` non ha mostrato contributo marginale. Le cinque osservabili rimanenti sono comuni ad attributore, discriminatore e generatore QKD. Una seconda famiglia di simulazioni con deriva e intermittenza comprende 56.496 finestre su quindici semi; non e' impiegata nel protocollo stazionario di esclusione delle celle discusso nei risultati.

B. Dominio IDS

Il ramo classico usa NSL-KDD [11] e si concentra sulle famiglie `r2l` e `probe`; nella configurazione principale la classe `r2l` e' sottocampionata a uno squilibrio 1:1000, corrispondente a 53 attacchi disponibili per replica. Per rispettare i cinque ingressi del circuito viene applicata la sequenza standardizzazione $\to$ PCA a cinque componenti (circa 34% della varianza) $\to$ min–max in $[0, 1]$. Tutte le trasformazioni sono stimate esclusivamente sul sottocampione di training della singola replica; validazione e `KDDTest+` usano la stessa proiezione, senza riadattamento. Campioni reali e sintetici vengono infine troncati in $[0, 1]$. `KDDTest+` contiene attacchi non presenti nell'addestramento ed e' usato per la valutazione esterna, non per selezionare modelli o soglie.

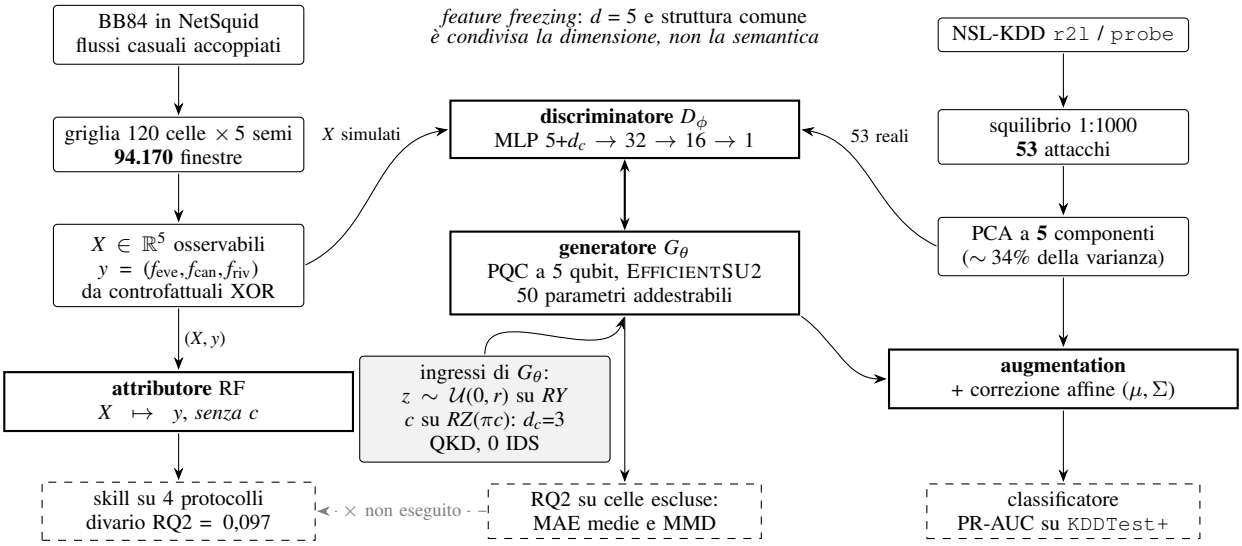


Fig. 1. Pipeline dei due rami. Generatore e discriminatore sono gli stessi nei due domini, a dimensionalità e topologia fissate dal vincolo di *feature freezing*; le cinque dimensioni sono osservabili fisiche del canale su QKD e componenti principali su IDS. L'attributore riceve le sole osservabili, *senza* le coordinate di cella, ed è un componente che non richiede le condizioni di scenario in ingresso. L'arco tratteggiato è l'anello non chiuso sperimentalmente: sulla griglia fisica simulata RQ2 è valutato come accordo distribuzionale, non addestrando l'attributore sulle finestre generate.

C. Protocolli, metriche e inferenza statistica

Per l'attribuzione QKD sono impiegati quattro protocolli: `random` (split 80/20 fra finestre di celle viste), `seed` (test su un seme non visto delle medesime celle), `interior` (celle interne escluse) e `boundary` (celle di bordo escluse). Lo skill e' definito come $1-\mathrm{MAE}_{\mathrm{modello}}/\mathrm{MAE}_{\mathrm{banale}}$, usando come previsione banale la media del training. Per la generazione QKD si distinguono un banco sintetico con struttura condizionale nota e la griglia BB84: nella seconda si confrontano errori sulle medie e MMD^2 con baseline generative e campioni reali di celle adiacenti. Per i confronti fra celle si usano differenze appaiate per (corsa, cella).

Su IDS vengono considerate dieci repliche indipendenti dello split, ciascuna con risottocampionamento e PCA riadattata, e due semi di addestramento per replica. La PR-AUC su `KDDTest+` e' la misura principale, affiancata da F_1 quando indicato. Gli intervalli al 95% sono calcolati mediante bootstrap che ricampiona repliche e semi; il conteggio dei segni considera le dieci medie per replica. Per i confronti QKD, gli intervalli incrociati ricampionano corse e celle. Trattandosi degli stessi protocolli e delle stesse celle, valutazioni diverse non devono essere interpretate automaticamente come prove indipendenti.

V. Attribuzione causale del QBER (O3)

A. Definizione dei target controfattuali

Per ogni posizione setacciata la simulazione registra tre indicatori di errore a causa singola, e_{eve}, e_{can} ed e_{riv}, ottenuti disattivando le altre cause nel calcolo sulla medesima posizione. L'errore osservato e' espresso dalla composizione bit per bit

$$e_{\mathrm{oss}} = e_{\mathrm{eve}} \oplus e_{\mathrm{can}} \oplus e_{\mathrm{riv}}. \tag{4}$$

Per una finestra, indicando con $\bar{e}_k$ il tasso dell'indicatore k, il target e' il vettore di quote relative di errore controfattuale

$$y = (f_{\mathrm{eve}}, f_{\mathrm{can}}, f_{\mathrm{riv}}), \qquad f_k = \frac{\bar{e}_k}{\sum_j \bar{e}_j}. \tag{5}$$

La somma delle quote e' unitaria quando il denominatore e' positivo: si tratta di una normalizzazione dei tassi a causa singola, *non* di una scomposizione additiva del QBER osservato. In 259 delle 94.170 finestre (0,275%), prive di errori attribuibili, il codice assegna convenzionalmente $y = (0, 0, 0)$. Tali casi sono concentrati nelle condizioni meno rumorose; sulle finestre restanti la somma delle quote vale uno entro l'errore numerico ($4{,}4 \cdot 10^{-16}$).

B. Verifica dell'identita' XOR e dei numeri casuali comuni

L'identita' dell'Eq. (4) e' verificata mediante enumerazione delle posizioni nel simulatore. La sua validita' all'interno di una corsa va distinta dalla coerenza *fra* configurazioni diverse, necessaria per costruire controfattuali accoppiati. Quest'ultima dipende dall'uso di *Common Random Numbers* (CRN): al variare di I_e, le posizioni intercettate sono annidate e, nelle posizioni comuni, le realizzazioni casuali di Eve, del canale e di Bob devono rimanere allineate. Il controllo sperimentale ha rilevato 0/299 divergenze con accoppiamento attivo, contro 87/299 (29,1%) disattivandolo. Nel simulatore tali verifiche permettono di trattare gli indicatori a causa singola come controfattuali determinati dalla medesima realizzazione casuale, senza estendere la pretesa di esattezza a osservazioni fisiche non simulate.

C. Non additivita' e identificabilita'

La composizione XOR non implica additivita' dei tassi: per due errori indipendenti $P(A \oplus B) = P(A) + P(B) - 2P(A)P(B)$. Le inversioni simultanee possono quindi cancellarsi. Nel dataset

il residuo $\sum_k \bar{e}_k - \bar{e}_{\text{oss}}$ presenta mediana zero, media +0,006 e massimo assoluto 0,080 in unita' di QBER; la somma semplice e' pertanto soltanto un'approssimazione a basso errore. Un secondo limite riguarda la griglia sperimentale: essa varia intercettazione e parametri del canale, mentre la probabilita' di errore del rivelatore resta costante. La componente f_{riv} non dispone quindi di un asse di variazione autonomo, circostanza rilevante per interpretare le prestazioni dell'attributore.

VI. Baseline classica di attribuzione QKD

La possibilita' di stimare le quote y dalle sole cinque osservabili e' valutata indipendentemente dalla QGAN. La baseline principale e' una Multi-Output Random Forest da 100 alberi; Histogram Gradient Boosting e regressione ridge costituiscono controlli sulla dipendenza dalla classe di modello. La Tabella I riporta la prestazione della foresta sui quattro protocolli introdotti nella Sezione IV. I MAE non sono direttamente comparabili fra split con diversa distribuzione dei target: si utilizza quindi lo skill rispetto al predittore banale.

TABLE I
Attributore classico (Random Forest) sui quattro protocolli, griglia da 94.170 finestre. Lo skill è la frazione di errore del riferimento banale eliminata dal modello.

Protocollo	**MAE**	**MAE banale**	**Skill**
random	$0{,}0856 \pm 0{,}0006$	0,1965	$0{,}564 \pm 0{,}003$
boundary	$0{,}1002 \pm 0{,}0083$	0,2079	$0{,}516 \pm 0{,}042$
interior	$0{,}0725 \pm 0{,}0126$	0,1365	$0{,}467 \pm 0{,}098$
seed	$\mathbf{0{,}1174 \pm 0{,}0018}$	0,1966	$\mathbf{0{,}403 \pm 0{,}008}$

Il valore piu' basso si osserva nel protocollo `seed` (skill 0,403), sebbene le celle fisiche siano gia' presenti nel training: la variabilita' fra realizzazioni della stessa configurazione e' un ostacolo rilevante, non riducibile alla sola distanza geometrica fra celle. Anche boosting e ridge degradano nello stesso ordine; sul protocollo `interior` raggiungono rispettivamente 0,299 e 0,108 contro 0,467 della foresta. Su `seed` lo skill per componente e' 0,535 per f_{eve}, 0,265 per f_{can} e 0,316 per f_{riv}: la separazione fra rumore di canale e rivelatore risulta piu' difficile della stima della componente di intercettazione.

Il divario fra `random` e `interior`, $0{,}564 - 0{,}467 = 0{,}097$ di skill, costituisce un riferimento per una futura valutazione dell'augmentation dell'attributore, non una prestazione gia' ottenuta grazie alla QGAN. Una variante binaria su 36 celle non estreme in I_e raggiunge accuracy $0{,}9269 \pm 0{,}0214$ (baseline banale 0,8148) e macro-F_1 0,8708; il macro-F_1 0,8803 riportato da Isha *et al.* [4] e' indicativo soltanto, perche' simulatori, feature e tipologie di attacco non coincidono.

VII. Risultati della generazione QKD (RQ2)

Dopo avere definito le quote controfattuali e la difficolta' della loro predizione, valutiamo una questione distinta: se il generatore condizionato riesca a riprodurre osservazioni X per configurazioni non incluse nell'addestramento. Questa valutazione misura fedelta' distribuzionale, non il miglioramento dello skill dell'attributore descritto nella sezione precedente.

A. Esperimento su griglia sintetica

Nel banco con struttura condizionale nota, la generazione su celle escluse produce un incremento medio di skill pari a +0,244: 18 corse su 20 sono positive ($p = 0{,}0004$) e l'intervallo incrociato al 95% e' $[+0{,}017, +0{,}433]$. Il risultato e' favorevole ma non particolarmente preciso: il limite inferiore e' vicino allo zero e il 55% della varianza si colloca fra celle, di cui soltanto otto distinte. Aumentare il numero di corse non sostituisce quindi l'osservazione di nuove celle indipendenti.

B. Generazione sulla griglia fisica simulata

Nel banco BB84, cinque corse escludono ciascuna 12 delle 24 celle interne. Si ottengono 60 contrasti su 23 celle distinte, appaiati per (corsa, cella). Il generatore condizionato e' confrontato con un generatore non condizionato, una media globale, il dato reale della cella piu' vicina e finestre reali traslate sulla media interpolata da celle adiacenti. L'ultimo riferimento conserva la struttura empirica delle osservazioni e riceve le stesse coordinate di scenario del generatore.

TABLE II
Generazione QKD su griglia fisica simulata (MAE e MMD^2), contrasti appaiati su (corsa, cella): 5 corse, 23 celle, 60 coppie. Segno positivo quando il generatore condizionato vince. Intervalli incrociati al 95%, che ricampionano sia le corse sia le celle.

Asse	**Riferimento**	**Differenza**	**Segni**
MAE	non condizionato	+0,0899	5/5
MAE	media globale	+0,0840	5/5
MAE	vicino più prossimo	+0,0105*	4/5
MAE	**interp. lineare**	$\mathbf{-0{,}0459}$	0/5
MMD^2	media globale	+0,2823	5/5
MMD^2	non condizionato	+0,2474	5/5
MMD^2	vicino più prossimo	+0,0885	5/5
MMD^2	**interp. lineare**	$\mathbf{-0{,}0628}$	0/5
livelli dopo il ricentraggio sulla media vera			
MMD^2	condizionato	$0{,}0657 \rightarrow 0{,}00060$	
MMD^2	non condizionato	$0{,}3140 \rightarrow 0{,}09981$	
MMD^2	**vicino (reale)**	$0{,}1541 \rightarrow \mathbf{-0{,}00011}$	
eccesso sul pavimento interno alla cella (−0,00025)			
MMD^2	segnale disponibile	+0,00014 [+0,00011, +0,00018]	5/5
MMD^2	**errore del generatore**	**+0,00085** [+0,00057, +0,00116]	5/5
MMD^2	interp. lineare	+0,00308 [+0,00115, +0,00531]	5/5

*L'unico intervallo incrociato che contiene lo zero: $[-0{,}005, +0{,}024]$. Tutti gli altri lo escludono. Nel blocco inferiore la MMD^2 negativa del vicino reale ricentrato indica discrepanza stimata nulla: la stima è una U-statistica non distorta, che oltrepassa lo zero quando le due distribuzioni coincidono.

La Tabella II mostra che il condizionato supera le baseline costruite semplici su MAE delle medie e MMD^2, e il vicino reale sulla misura distribuzionale. Non supera pero' l'interpolazione basata su finestre reali: i contrasti sono $-0{,}0459$ in MAE e $-0{,}0628$ in MMD^2, con zero corse positive su cinque. Il confronto con il vicino sulla media (+0,0105) e' l'unico con intervallo che comprende lo zero, $[-0{,}005, +0{,}024]$. La presenza di informazione condizionale non dimostra quindi un vantaggio del generatore rispetto a un riuso appropriato dei dati fisici simulati.

C. Errore di media, errore di forma e pavimento statistico

Per distinguere le due componenti del disallineamento, i campioni generati vengono ricentrati *a posteriori* sulla vera media della cella esclusa. Si tratta di una diagnostica che usa informazione di test e non puo' essere impiegata come inferenza autonoma. La MMD^2 del generatore condizionato passa da 0,0657 a 0,00060, corrispondente a una riduzione del 99,1%; per il non condizionato passa da 0,3140 a 0,09981 (riduzione del 68%). Il ricentraggio permette dunque di individuare nella posizione della distribuzione il contributo dominante alla discrepanza del condizionato, pur lasciando un errore di forma da misurare.

Il riferimento statistico non e' zero: la U-statistica non distorta di MMD^2 puo' essere negativa quando le distribuzioni coincidono, e il pareggiamento delle medie campionarie introduce un bias nella costruzione ricentrata. Il pavimento, definito mediante due meta' delle finestre reali della stessa cella con una meta' ricentrata sull'altra, vale $-0{,}00025$ sulle medesime celle e corse dei contrasti; una verifica indipendente sulla griglia restituisce $-0{,}00026$. Rispetto al pavimento, il segnale di variazione di forma fra celle vicine e' +0,00014 (IC $[+0{,}00011, +0{,}00018]$), mentre l'errore di forma del generatore e' +0,00085 (IC $[+0{,}00057, +0{,}00116]$): circa sei volte maggiore. Gli intervalli restano distinti secondo il bootstrap applicato alla campagna osservata; non costituiscono una verifica su nuove celle indipendenti. L'interpolante lineare presenta eccesso +0,00308, dovuto nel confronto ricentrato alla diversa stima della media. Ne risultano due bersagli distinti per il generatore: migliorare la risposta della media alle condizioni e ridurre l'errore residuo di forma al livello del segnale disponibile.

VIII. Risultati IDS (RQ2)

Passiamo al secondo dominio, nel quale i campioni sintetici hanno una valutazione *downstream* diretta: vengono utilizzati per addestrare un classificatore e confrontati sul test esterno `KDDTest+`. In questo caso la domanda non e' se la distribuzione generata assomigli al training, ma se migliori il riconoscimento di attacchi non osservati. SMOTE costituisce la baseline principale.

A. Augmentation e generalizzazione fuori distribuzione

La Tabella III riporta le differenze di PR-AUC rispetto a SMOTE per dieci repliche indipendenti e due semi ciascuna. La QGAN con correzione affine di media e covarianza ottiene +0,1237 (IC $[+0{,}084, +0{,}161]$), con differenza positiva in tutte le dieci repliche. Jitter al 30% e al 10% ottengono rispettivamente +0,1214 e +0,1192, mentre la QGAN senza correzione (+0,0034, IC che include zero) non emerge rispetto a SMOTE.

Il protocollo modifica anche l'ordinamento dei metodi: nella validazione estratta dal medesimo split del training SMOTE precede di 0,015 di F_1 la QGAN corretta, mentre su `KDDTest+` quest'ultima precede SMOTE di 0,124 di PR-AUC. Poiche' le due differenze usano metriche differenti, descrivono un'inversione di ordinamento e non una misura unica di miglioramento. In un precedente singolo split il divario relativo della QGAN era $-0{,}197$; sulle dieci repliche diventa $-0{,}112$, illustrando quanto la sottoselezione di soli 53 attacchi possa condizionare una conclusione.

TABLE III
RAMO IDS: PR-AUC SU KDDTEST+, DIFFERENZA DA SMOTE. INTERVALLI AL 95% DA BOOTSTRAP INCROCIATO SU REPLICHE × SEMI; I SEGNI INDICANO LE REPLICHE CON DIFFERENZA POSITIVA SU DIECI. L'ASTERISCO MARCA GLI INTERVALLI CHE CONTENGONO LO ZERO.

Variante	Media	Int. 95%	Segni
QGAN + corr. affine	**+0,1237**	[+0,084, +0,161]	10/10
Jitter 0,30×	+0,1214	[+0,090, +0,158]	10/10
Jitter 0,10×	+0,1192	[+0,088, +0,160]	10/10
Gaussiana, momenti imposti	+0,0973	[+0,042, +0,150]	8/10
Gaussiana (μ, Σ)	+0,0915	[+0,040, +0,138]	8/10
Jitter 0,03×	+0,0539	[+0,008, +0,103]	8/10
QGAN	+0,0034	[−0,051, +0,049]*	5/10
Duplicazione	−0,0635	[−0,086, −0,041]	0/10
Nessuna augmentation	−0,0743	[−0,098, −0,054]	0/10
`class_weight` bilanc.	−0,0897	[−0,111, −0,068]	0/10

B. Controllo QGAN–Gaussiana e ruolo dei momenti

Per separare l'effetto della distribuzione generativa da quello della calibrazione statistica, la QGAN viene confrontata con una gaussiana multivariata sottoposta alla medesima correzione affine dei momenti. Dopo tale trasformazione si applica il clipping in $[0, 1]$, che puo' modificarli nuovamente. Gli scarti relativi di covarianza rispetto ai dati reali, misurati *dopo* il clipping, sono 0,0124 per QGAN e 0,0131 per gaussiana, contro un pavimento di ricampionamento pari a 0,2603. Queste misure non sono una stima diretta dello scarto reciproco fra le nuvole e non dimostrano uguaglianza esatta dei loro momenti.

TABLE IV
CONTRASTO DECISIVO QGAN − GAUSSIANA A MOMENTI CORRISPONDENTI. TUTTI GLI INTERVALLI INCROCIATI CONTENGONO LO ZERO.

Metrica	Insieme	reps	Media	Int. 95%
F_1 a soglia	validation	4	+0,0003	[−0,013, +0,013]
F_1 a soglia	test	4	+0,0422	[−0,004, +0,091]
F_1 oracolo	test	4	+0,0218	[−0,014, +0,052]
PR-AUC	test	4	+0,0263	[−0,008, +0,060]
PR-AUC	test	8	+0,0085	[−0,027, +0,044]
F_1 oracolo	test	8	−0,0042	[−0,040, +0,028]

Le sei valutazioni della Tabella IV presentano intervalli che contengono zero; il confronto diretto di PR-AUC sul test a quattro ripetizioni vale +0,0263 (IC $[-0{,}008, +0{,}060]$). Non emerge quindi un vantaggio statisticamente robusto della struttura del circuito sulla baseline gaussiana considerata; neppure si puo' inferire equivalenza, poiche' la potenza con dieci repliche e' limitata. Le sei misure condividono inoltre parte dei medesimi dati e non rappresentano sei prove indipendenti. A otto ripetizioni l'effetto QGAN–Gaussiana in PR-AUC si riduce a +0,0085.

C. Robustezza, MMD e interpretazione geometrica

Un'ipotesi coerente con i risultati e' che l'augmentation utile su attacchi nuovi dipenda dalla copertura di regioni non accessibili alle interpolazioni convesse di SMOTE: jitter, gaussiana e QGAN corretta possono produrre campioni esterni all'inviluppo dei 53 attacchi. Questa spiegazione non e' stata ancora confermata dalla misura diretta della massa sintetica esterna all'inviluppo. Le ablazioni delle dispersioni per feature non sostengono un effetto isolato della loro scala (modifica di SMOTE: $-0{,}0110$, IC $[-0{,}041, +0{,}017]$; riallineamento QGAN: $-0{,}0081$, IC $[-0{,}079, +0{,}076]$); e' invece utile la correzione congiunta di media e covarianza (+0,1202, IC $[+0{,}080, +0{,}168]$).

La MMD usata per l'arresto non mostra una relazione affidabile con l'utilita' nel classificatore. La correlazione di rango con le prestazioni cambia da $\rho = -0{,}20$ in validazione a +0,25 sul test con soglia trasferita e non e' significativa sulle metriche prive di soglia. Duplicazione e jitter al 10%, per esempio, hanno MMD distanti 0,0005 ma F_1 distanti 0,169. Quanto al clipping, un audit su `KDDTest+` trova il 2,93% delle osservazioni con almeno una componente troncata: 365 campioni benigni su 9.711 e nessuno dei 2.754 attacchi, con superamento massimo 0,031. Il clipping non altera direttamente le feature degli attacchi, ma puo' comunque modificare la PR-AUC attraverso i punteggi dei benigni; la verifica diretta senza clipping resta da eseguire.

IX. Discussione e limiti

A. Portabilita' dell'architettura (O1)

La QGAN e' utilizzabile con la stessa struttura di base in entrambi i domini, ma la calibrazione non e' trasferibile senza adattamento. Oltre ai raggi latenti differenti (0,82 contro 0,93), il numero di passi utili cambia di circa un ordine di grandezza: su QKD l'ottimo si colloca fra 2.900 e 3.400 step, su IDS la mediana e' 275 (massimo 400 in venti corse). Su QKD il discriminatore presenta inoltre una soglia di capacita': ridurlo da 32×16 a 16 unita' comporta $-0{,}195$ di skill (IC $[-0{,}410, -0{,}006]$, 4/20 segni, $p = 0{,}012$), a 8 unita' $-0{,}340$ (IC $[-0{,}590, -0{,}131]$, 4/20), mentre l'espansione a 64×32 non produce un beneficio robusto (+0,055, IC comprendente zero, 9/20). Tali ablazioni non sono state replicate sul ramo IDS. Un raggio latente scalare lascia inoltre disallineamenti delle dispersioni per componente fino a un fattore 4,5; la profondita' dell'ansatz deve percio' essere valutata separatamente dalla qualita' della calibrazione.

B. Qualita' generativa e utilita' (RQ2)

I due casi di studio mostrano che il comportamento di una metrica distribuzionale non coincide automaticamente con l'utilita' del campione sintetico. Su IDS la correzione dei momenti migliora il test fuori distribuzione, ma una gaussiana calibrata produce prestazioni confrontabili; su QKD il generatore condizionato migliora rispetto ai riferimenti semplici senza superare il riuso di osservazioni da celle adiacenti. Non emerge da tali confronti un vantaggio quantistico robusto. La solidita' di questa interpretazione dipende dai protocolli e dai controlli di robustezza, i cui effetti sulle conclusioni sono ripresi nel bilancio finale.

C. Validita' sperimentale e integrazione incompleta

Tutti i risultati QKD derivano da simulazione. Inoltre il generatore condizionato riceve I_e, lunghezza e depolarizzazione come coordinate di scenario: in una rete operativa l'intensita' dell'intercettazione non sarebbe nota. L'attributore classico, invece, predice y dalle cinque osservabili senza ricevere tali coordinate; la sua possibile utilita' operativa rimane comunque non validata su hardware reale. Il collegamento *generatore* $\rightarrow$ *attributore* non e' stato testato: sulla griglia fisica simulata si misurano MAE e MMD^2 dei campioni generati, non lo skill di un attributore riaddestrato su di essi. Il riferimento di 0,097 in skill della Sezione VI non e' confrontabile direttamente con i risultati distribuzionali della Sezione VII.

Su IDS il vincolo dei cinque qubit lascia nella PCA circa il 34% della varianza, mentre lo squilibrio estremo e la scelta di NSL-KDD limitano la generalizzabilita' ad altri dataset. Nei contrasti QKD il numero di celle indipendenti rimane limitato nonostante le molte finestre e corse. Alcune verifiche, compresi l'effetto indiretto del clipping sulla PR-AUC, l'analisi geometrica dell'inviluppo convesso e la misura diretta della differenza dei momenti fra QGAN e gaussiana, sono ancora aperte.

X. Conclusioni e sviluppi futuri

A. Conclusioni

La sperimentazione documenta una portabilita' *architetturale* della QGAN a dimensionalita' fissa, non il trasferimento diretto di una calibrazione fra domini. L'augmentation IDS puo' migliorare la generalizzazione fuori distribuzione, senza dimostrare un contributo specificamente quantistico rispetto alle baseline classiche calibrate. La generazione QKD condizionata apprende parte della variazione fra scenari, ma non raggiunge il riferimento costruito da osservazioni reali di celle vicine. L'attribuzione controfattuale del QBER costituisce un contributo distinto: definizione e verifica nel simulatore dei target e valutazione di una baseline classica, senza collegamento generativo gia' dimostrato. Nel complesso, la scelta della metrica e del protocollo di test influenza l'interpretazione almeno quanto l'architettura.

Tre conclusioni intermedie sono state ritirate dopo controlli dichiarati prima della misura. Primo, il divario IDS stimato su un unico split ($-0{,}197$) si ridimensiona a $-0{,}112$ su dieci repliche: lo split iniziale ne sovrastimava l'entita' di circa l'80%. Secondo, l'ipotesi che la sola distorsione delle dispersioni per feature spiegasse il risultato e' stata smentita in entrambe le direzioni sperimentali. Terzo, l'apparente effetto negativo dell'aumento di profondita' dell'ansatz da quattro a otto ripetizioni non era isolabile dalla calibrazione del latente. Ogni revisione interpretativa e' derivata da un controllo stabilito prima della relativa misura: *questa pratica di verifica delle ipotesi, piu' dei singoli valori ottenuti, e' il contributo metodologico che intendiamo sottolineare*.

B. Sviluppi futuri

La priorita' e' chiudere il collegamento QGAN–attributore, addestrando il regressore sulle finestre sintetiche di celle escluse e misurandone lo skill su osservazioni reali della simulazione. Senza riaddestrare il generatore e' inoltre possibile confrontare la PR-AUC IDS con e senza clipping e misurare la frazione di campioni sintetici esterni all'inviluppo convesso. Sul ramo QKD nuovi esperimenti dovrebbero separare la risposta della media dalla fedelta' di forma, riducendo l'eccesso di MMD^2 da 0,00085 verso il segnale osservabile di 0,00014, e aumentare la copertura di celle indipendenti. La validazione su CICIDS2017, griglie QKD non stazionarie piu' articolate e, in prospettiva, dispositivi NISQ permetterebbe di verificare quanto le conclusioni dipendano dall'attuale banco simulato.

REFERENCES

[1] C. Zoufal, A. Lucchi, and S. Woerner, "Quantum generative adversarial networks for learning and loading random distributions," *npj Quantum Information*, vol. 5, no. 1, p. 103, 2019.

[2] C. H. Bennett and G. Brassard, "Quantum cryptography: Public key distribution and coin tossing," in *Proceedings of the IEEE International Conference on Computers, Systems and Signal Processing*, Bangalore, India, 1984, pp. 175–179, ristampato in Theoretical Computer Science 560:7–11, 2014. https://doi.org/10.1016/j.tcs.2014.05.025.

[3] J. Xu, X. Ma, J. Liu, C. Zhang, H. Li, X. Zhou, and Q. Wang, "Automatically identifying imperfections and attacks in practical quantum key distribution systems via machine learning," *Science China Information Sciences*, vol. 67, no. 10, p. 202501, 2024.

[4] Isha, D. Singh, D. Kumar, S. K. Pal, P. Hambarde, and A. Shukla, "Beyond the QBER threshold: A temporal QBER based machine learning framework for multi attack detection in BB84 QKD," Aug. 2026. [Online]. Available: https://arxiv.org/abs/2608.04047

[5] A. L. Buczak and E. Guven, "A survey of data mining and machine learning methods for cyber security intrusion detection," *IEEE Communications Surveys & Tutorials*, vol. 18, no. 2, pp. 1153–1176, 2016.

[6] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.

[7] K. Mitarai, M. Negoro, M. Kitagawa, and K. Fujii, "Quantum circuit learning," *Physical Review A*, vol. 98, p. 032309, 2018.

[8] M. Schuld, V. Bergholm, C. Gogolin, J. Izaac, and N. Killoran, "Evaluating analytic gradients on quantum hardware," *Physical Review A*, vol. 99, p. 032331, 2019.

[9] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, and A. Smola, "A kernel two-sample test," *Journal of Machine Learning Research*, vol. 13, pp. 723–773, 2012.

[10] T. Coopmans, R. Knegjens, A. Dahlberg, D. Maier, L. Nijsten, J. de Oliveira Filho, M. Papendrecht, J. Rabbie, F. Rozpędek, M. Skrzypczyk, L. Wubben, W. de Jong, D. Podareanu, A. Torres-Knoop, D. Elkouss, and S. Wehner, "NetSquid, a NETwork Simulator for QUantum Information using Discrete events," *Communications Physics*, vol. 4, p. 164, 2021.

[11] M. Tavallaee, E. Bagheri, W. Lu, and A. A. Ghorbani, "A detailed analysis of the KDD CUP 99 data set," in *IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA)*, 2009.